

听 Rubin 和 Imbens 的话：DID 中处理配置机制讨论的实践指导

许文立 *

23rd Aug 2024

摘要: Rubin (2008)、Imbens & Xu(2024) 均强调, “因果效应分析应该从理解处理配置机制开始”。但大部分经验研究忽略了处理配置机制的阐述和分析, 由此可能导致因果效应出现偏误, 甚至得到错误的结论。本文以双重差分研究设计为例, 基于最新理论进展和模拟数据, 讨论不同类型的处理配置机制对双重差分的平行趋势和平均处理效应的影响。结果显示: 基于处理前潜在结果、固定效应等选择机制并不会打破平行趋势, 经典的 TWFE 估计量仍然无偏; 基于协变量和未处理潜在结果变化的选择机制则会导致经典 TWFE 估计量有偏, 需要稳健的估计量; 基于处理后结果预期的选择机制则会打破平行趋势假设, DID 研究设计可能不再适用。基于此, 本文给出经验研究中处理配置机制讨论的定性和定量分析指南, 也给出应对选择机制偏误的稳健估计量。

关键词: 处理配置机制; 双重差分法; 平行趋势; 应用指南

*经济学博士, 研究兴趣是中国宏观经济政策、环境与气候政策、DSGE、DID 与计算经济学, xuweny87@hotmail.com。本文灵感来源于 Cuuningham (2024) 撰写的一系列关于 “DID 规定步骤” 的 blog 文章, 并在他的内容基础上增加了 “选择机制的理论框架” 和一些讨论分析, 尤其是关于选择机制的稳健估计量。写这篇文章是受到了江西财经大学王岳龙老师的鼓励, 他认为将 “宏观研学会” 公众号笔记重写成学术论文对中国大陆地区的研究者和学生们有较强的应用指导价值。而我不愿写成论文的主要原因是这种文章在中文期刊发表较为困难。在写作和修改过程中, 王岳龙老师也给我提供了许多选择机制的稳健估计量, 在此感谢。本文最新版本和 stata 数据和 do 文件请在我的<https://wenddymacro.github.io/Wenddy-XU/>。

1 引言

“人们无时无刻不在面临着权衡取舍”——这是曼昆的经典教材《经济学原理》开篇的经济学十大原理之一。如果人们要做一个好的决策，她必须要理解这个决策产生的结果/效果。这不仅适用于个体决策，也适用于政策制定者。政策实施的效果通常是学界、业界和政策制定者最关心的事情。而评估政策的效果非常具有挑战性（诺贝尔经济学奖委员会，2021）。在经济学中，鲁宾因果模型（Rubin causal model, RCM）是思考政策因果效应最常用的工具之一，它主要有两个必要的组成部分——潜在结果和处理配置机制。前者是概念性的，主要定义因果效应。而后者对于经验研究中的研究设计直观重要。因此，本文主要关注处理配置机制或者选择进入处理¹。

经济学界早在 1975 年之前就已经开始讨论处理配置机制。例如，Roy (1951) 认为，每个个体都会选择带来最优结果的处理。另一个著名的例子就是 Haavelmo (1944) 的供给与需求行为理论。这些早期的讨论并没有形成“处理配置机制”的正式概念和框架，也没有基于处理配置机制来进行因果效应推断。相反，经济学界开始用回归模型从协变量和处理变量中预测可观测结果，并且对一些回归系数和误差项施加一些限制。这些模型限制均属于处理配置机制的范畴。直到 1975 年，Rubin (1975) 给出了处理配置机制的一般化定义，即处理配置可能依赖于潜在结果。而且当代的因果推断方法均来自于 Fisher (1925) 和 Neyman (1923) 等提出的随机配置机制假设基础上。这些概念性框架均说明，相较于估计、推断模型本身来说，处理配置机制对于因果效应推断发挥着根本性作用（Rubin, 2007）。

20 世纪 80 年代后，越来越多的经济学文献开始对处理配置机制或者选择机制施加明确的限制，以此来发展并比较处理效应的不同估计方法。例如，Ashenfelter and Card (1985) 假设基于固定效应选择进入处理。其它的文献则基于未处理潜在结果、基于处理效应、基于其它经济模型等等选择机制（Heckman and Robb, 1985; Card and Hyslop, 2005; Chabe-Ferret, 2015; Blundell and Dias, 2009; de Chaisemartin and D’Haultfoeuille, 2018; Verdier, 2020; Dube et al., 2023; Marx et al., 2024; Viviano and Bradic, 2024）。最近，Ghanem et al. (2024) 在上述研究基础上建立了更加一般化的处理配置机制框架来研究双重差分 (DID) 法的平行趋势假设，并推导了其必要和充分条件。基于此，作者提出了基于选择 (selection-based) 的敏感性分析方法。

正如 Rubin (2007) 指出，“在实践中，处理配置机制的分析对于因果效应推断绝对是必要的步骤”。而且 Imbens 和 Xu (2024) 更强调，“因果效应分析的第一步是理解处理配置机制”。但在经验研究中，研究者通常忽略了处理配置机制的分析（Rubin, 2007）。相反，研究者会用“准随机”来指代处理配置，以此来支持所选研究设计（Ghanem et al., 2024）。尽管“准随机配置”处理也是一种处理配置机制，但是研究者通常并没有进一步阐明“准随机配置”的相关内容。这都是因为经济学界缺乏有关处理配置机制的理论和实践指导。本

¹在本文中，处理配置机制和选择进入处理表示同一含义，因此交叉使用。

文以 DID 研究设计为例，²主要关注处理配置机制的理论进展和实践指导，尤其是基于最新理论进展，结合模拟数据分析不同处理配置机制对 DID 估计量带来的偏误，以及对应的稳健估计量和实践建议。

2 潜在结果框架下的选择机制

本文首先基于 Robin (2007) 和 Ghanem et al. (2024) 的潜在因果框架给出处理效应的定义，然后定义选择机制。考察经典的 2×2 DID 设定：个体 i 划分成两类组群，有两期——第 1 期和第 2 期。定义 D_{it} 为处理变量， Y_{it} 表示个体 i 的结果变量。个体 i 基于一定的原因做出选择处理的决策。如果个体 i 在第 1 期未处理，在第 2 期选择处理，它就属于处理组 ($G_i = 1$)，如果两期均为处理，就属于控制组 ($G_i = 0$)。个体 i 处于处理状态或者未处理状态所对应的潜在结果分别为 $Y_{it}(1)$ 和 $Y_{it}(0)$, $t = (1, 2)$ 。由此，第 i 个个体的处理效应 (δ_i) 可以定义为：

$$\delta_i = Y_{i2}(1) - Y_{i2}(0) \quad (1)$$

对于总体来说，平均处理效应 (ATE) 为：

$$ATE = E[\delta] = E[Y(1)] - E[Y(0)] \quad (2)$$

从式 (2) 可以明确地看出，ATE 并不依赖于哪个个体选择进入处理，哪个个体没有选择进入处理。因为它仅仅只是每个个体的处理效应的加权平均值。因此，这就意味着 ATE 并不依赖于选择机制。在 DID 研究设计中，要识别第 2 期的处理组平均处理效应 ($ATT = E[Y_{i2}(1) - Y_{i2}(0)|G_i = 1]$)，主要是通过 DID 估计量：

$$ATT = E[Y_{i2} - Y_{i1}|G_i = 1] - E[Y_{i2} - Y_{i1}|G_i = 0]$$

上式的等号右边是 DID 项，它要识别 ATT 必须要求平行趋势假设成立：

$$E[Y_{i2}(0) - Y_{i1}(0)|G_i = 1] = E[Y_{i2}(0) - Y_{i1}(0)|G_i = 0] \quad (3)$$

式 (3) 意味着，DID 的平行趋势假设包含反事实结果 $Y_{i2}(0)$ ，即“没有选择处理”的反事实，处理组的反事实结果在现实中观测不到，因此平行趋势假设不可能用现实数据来证

²本文选择以 DID 为例，主要是因为它是当前经济学经验研究中最常用、最重要的研究设计。例如，以“difference-in-differences”为关键词在谷歌学术(Google Scholar)中可以搜索出超过 50000 篇文章。de Chaisemartin 和 D’Haultfoeuille (2021) 统计了美国经济评论 (the American Economic Review) 2015-2019 年间每年谷歌学术引用率最高的 20 篇论文，共 100 篇，其中有 26 篇用了 DID 估计量。2020 年以来中文期刊上以“双重差分”为方法的发文数量每年都超过 1200 篇。NBER 和经济学 top5 期刊上以“双重差分”为方法的发文比例约为 23%，经济学 top5 期刊上的 DID 文献占比约为 16%(Currie et al., 2020)。由此可见，DID 是经济学研究领域最常用、最流行的准实验研究设计。

明是成立的。因此，为了识别 ATT，研究者通常会隐含着对未处理的潜在结果施加一些限制，例如，

$$Y_{it}(0) = f(\alpha_i, \alpha_t, \epsilon_{it}), i = 1, \dots, n; t = 1, 2 \quad (4)$$

其中， $\alpha_i, \alpha_t, \epsilon_{it}$ 分别表示时间不变不可观测因素（个体固定效应）、时变不可观测因素（时间固定效应）和时变因素。 $f()$ 表示不受限制的函数。这个函数允许研究者区分时变因素和时间不变因素，进而定义选择机制。而且上述结果模型包含了基于固定效应的选择机制，例如，Ashenfelter and Card(1985)。

下面，定义一个一般化的选择机制，在这种选择机制下，个体选择进入处理是基于 $(\alpha_i, \epsilon_{i1}, \epsilon_{i2})$ 和其它一些时间不变和时变因素 $(v_i, \eta_{i1}, \eta_{i2})$ ：

$$G_i = g(\alpha_i, \epsilon_{i1}, \epsilon_{i2}, v_i, \eta_{i1}, \eta_{i2})$$

上述选择机制包括许多不同类型的选择：随机选择、基于固定效应的选择、基于未处理潜在结果的选择、基于处理效应的选择、其它经济模型的选择（例如，Heckman and Robb, 1985; Chab´e-Ferret, 2015; Marx et al., 2023）。注意，因为 $G_i = D_{i2}$ ， $g()$ 也可以理解为 D_{i2} 的选择机制。

这就意味着， G_i 是实际选择机制。例如，企业选择进入碳排放交易市场的原因。注意，选择机制有六个元素：两个只有下标 i (α_i, v_i)，另外四个与两期（1 期和 2 期）和个体差异有关。总之，它们包括了时间不变的变量和时变变量。

- α_i （时间不变的特征）：一家企业可能更愿意参加碳排放权交易市场，仅仅是因为它是国有企业，或者处于传统化石能源行业。这是一种不随时间变化的企业特征。

- ϵ_{i1} （处理前时变冲击）：一家企业参与到碳排放权交易市场，仅仅是因为它在处理前经历了短暂（临时性）的冲击（能源价格冲击等等）。这可能使得企业更愿意参与碳交易市场。也许在第一期（处理前），全球能源市场发生了一些扰动使得企业的绩效或者碳排放量增加，例如，只有那些 $\epsilon_{i1} \geq 0$ 的企业才会选择进入处理。

- ϵ_{i2} （处理后时变冲击）：一家企业预期到未来会出现一些运营冲击（例如，减排政策收紧、碳税等等），因此，它们会为此做出一些准备，例如参与碳排放交易市场。这代表了基于未来预期的结果选择进入处理。

- v_i （时间不变的约束）：后面三项可以归类于“其它因素”。Cunningham(2024) 将其理解成企业面临的约束，例如，一些企业本来就高排放（需要大量的化石能源投入）。也许，对于 $v_i \leq X$ （ X 是恒定）的企业更可能参与碳交易市场。

- η_{i1} （处理前时变的约束）：在处理前时期，可能有一些临时性的因素在影响企业参与碳排放交易市场。这不同于 ϵ_{i1} ，因为它影响的是企业参与碳排放交易市场的约束条件，而不是直接影响企业的碳排放/结果。

- η_{i2} （处理后时变的约束）：企业可能预期到未来影响碳排放的约束条件会发生变化，因此，现在参与碳排放市场以做好准备。

定义 G_{all} 表示所有选择机制的集合。

根据上述选择机制的定义，经验研究中常见的选择机制类型主要有以下几种：

- 类型一：基于处理前结果的选择。考虑处理前结果是否超过某一阈值的选择机制。定义 ω_i 代表个体在决定是否选择进入处理时可用的信息集：

$$G_i = 1\{E[Y_{i1}(0)|\omega_i] \geq E[C_i|\omega_i]\}$$

例如， G_i 表示参与到碳排放交易市场， $Y_{i1}(0)$ 表示未处理（处理前）潜在碳排放量， C_i 是个体异质的阈值——假设为 η_{i1} 的一种要素。也就是说，在第 1 期（处理前时期），当企业的碳排放量超过一定的阈值 C 时，企业会选择进入碳交易市场。

- 类型二：基于处理前结果变化的选择。考虑处理前结果变量是否超过某一阈值的选择机制。定义 ω_i 代表个体在决定是否选择进入处理时可用的信息集：

$$G_i = 1\{E[\Delta Y_{i1}(0)|\omega_i] \geq E[C_i|\omega_i]\}$$

其中， $\Delta Y_{i1}(0) = Y_{i1}(0) - Y_{i0}(0)$ 表示处理前两期的潜在结果变化。例如， G_i 表示参与到碳排放交易市场， $Y_{i1}(0)$ 表示未处理（处理前 1 期）潜在碳排放量， $Y_{i0}(0)$ 表示未处理（处理前 2 期）潜在碳排放量， C_i 是个体异质的阈值。也就是说，在第 1 期（处理前时期），当企业的碳排放量的变化超过一定的阈值 C 时，企业会选择进入碳交易市场。这种选择机制是著名的“阿申菲尔特沉降（The Ashenfelter dip）”（Ashenfelter, 1978）。这种现象在经济社会中非常常见，例如，工人参加就业培训可能是因为以前经历了收入下降，球队换教练可能是因为前几场比赛都输球。

- 类型三：基于可观测个体特征的选择。考虑处理前个体的一些特征是否超过某一阈值的选择机制。定义 ω_i 代表个体在决定是否选择进入处理时可用的信息集：

$$G_i = 1\{E[X_{i1}|\omega_i] \geq E[C_i|\omega_i]\}$$

其中， X_{i1} 表示第 1 期的个体特征，它并不受到处理状态的影响。为了与个体固定效应区分，假设处理前个体特征对潜在结果有异质性效应。例如，只有那些创立年限超过 5 年，且企业规模在 500 万以上的企业才会选择进入碳交易市场。企业的运营年限和规模都对碳排放量有异质性效应，例如，企业经营时间越长、规模越大，越依赖于传统的生产技术和能源，其碳排放量可能越大。

- 类型四：基于固定效应的选择。DID 方法使用双向固定效应 (TWFE) 模型，这意味着 DID 允许基于时间不变的不可观测因素（固定效应）的选择：

$$G_i = 1\{\alpha_i \leq C\}$$

这种选择机制对应于经典的 Ashenfelter and Card (1985) 劳动就业培训的效应。

- 类型五：基于处理效应的选择。如果来自处理的预期碳排放量 $E[Y_{i2}(1) - Y_{i2}(0)|\omega_i]$ 超过了处理的预期成本 $E[C_{i2}|\omega_i]$,

$$G_i = 1\{E[Y_{i2}(1) - Y_{i2}(0)|\omega_i] \geq E[C_{i2}|\omega_i]\}$$

3 模拟

这一部分使用模拟数据来说明第二部分呈现的五种常见选择机制。为了专注于选择机制，简化处理模式，模拟数据的数据生成过程 (DGP) 均为同一处理时点的情形。首先，简要描述基于每种选择机制的 DGPs 主要特征，然后用传统 TWFE 和事件研究法估计 ATT，并呈现选择机制对 ATT 的 TWFE 估计量可能造成的偏误，最后给出相应的选择机制稳健估计量和估计结果。

3.1 基于不可观测固定效应的选择机制

考察一个由 1000 个家企业 ($i=1, \dots, 1000$), 十年 ($t=2015, \dots, 2024$) 所组成的面板数据。假设 2019 年建设碳排放权交易市场，有些企业决定参与其中，另一些企业则没有参与，定义初次参与时点 $g = 2019$ ，也就是说，对于参与碳交易市场的企业处理后有五期：2020、2021、2022、2023、2024；而 2015-2019 则为五个处理前时期。结果变量 Y_{it} 表示企业的碳排放量，其数据产生过程 (DGPs) 为：

$$Y_{it} = Trend_t + \alpha_i + \tau_{it} + 300\epsilon_{it} \quad (5)$$

其中， $Trend = 1000 + 100(year - 2014)$ 表示恒定的碳排放趋势，即企业每年固定的碳排放量； $\alpha_i \sim N(0, 1)$ 表示企业固定效应，抽样于均为 0，方差为 1 的正态分布； $\epsilon_{it} \sim N(0, 1)$ 是误差项，其服从均值为 0，方差为 1 的正态分布。 τ_{it} 表示个体 i 在时点 t 的处理效应，其生成过程：

$$\tau_{it} = 1000(year - 2019) \times G_i(\omega_i) \quad (6)$$

其中， $G_i(\omega_i) = 1\{E[\alpha_i|\omega_i] \geq E[0|\omega_i]\}$ 指代选择机制，即只有企业固定效应 $\alpha_i > 0$ 的企业会选择进入碳交易市场。且 μ 表示企业的瞬时处理效应，令 $\mu_{2020} = 1000, \mu_{2021} = 2000, \mu_{2022} = 3000, \mu_{2023} = 4000, \mu_{2024} = 5000$ 。这意味着企业进入碳交易市场对碳排放量的真实处理效应随着时间而提高，即分别为 1000, 2000, 3000, 4000 和 5000。

在经验研究中，研究者经常质疑“参与碳交易市场的企业不同于未参与企业”。这通常表达的是与企业固定效应有关的时间不变的特征。这些特征既会影响企业参与碳交易市场，也会影响企业的碳排放量。基于固定效应的选择机制可能引起的内生性问题并不会打破 DID 的平行趋势假设 (Ghanem et al., 2024)，因为差分可以消除时间不变的固定效应，这也是面

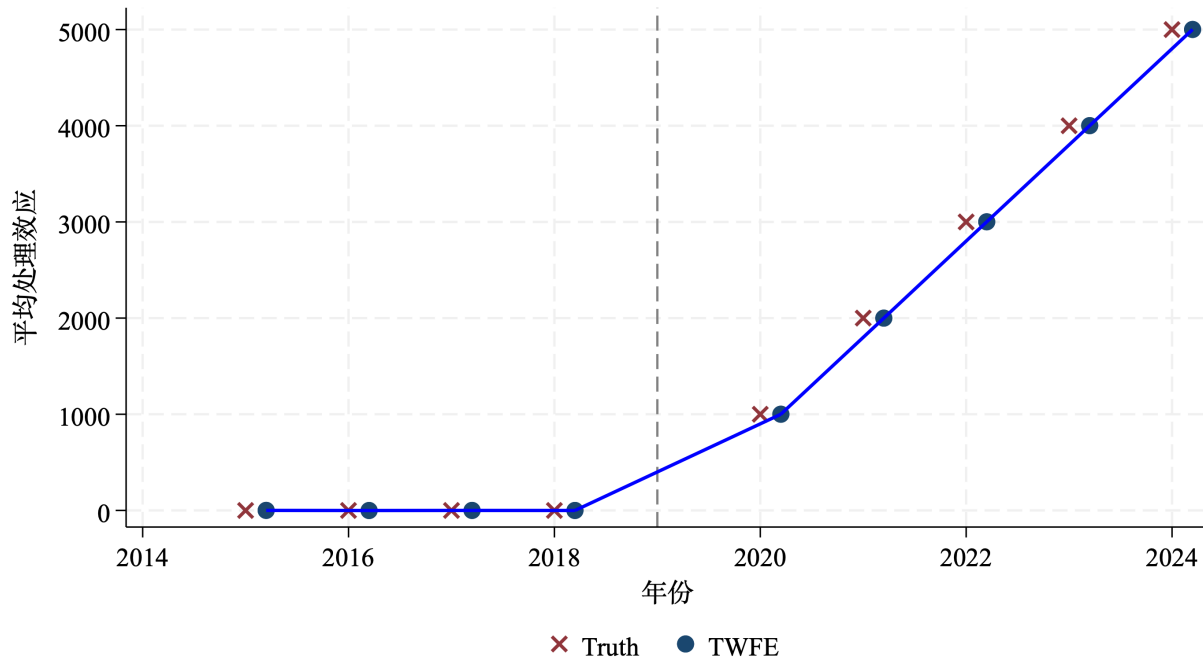
板数据中的因果效应推断广泛使用固定效应模型最重要的原因之一（Angrist and Pischke, 2009; Miller et al., 2023）。

基于此，在基于固定效应的选择机制下，本文的模拟数据处理发生在 2020 年，处理前有五年，处理后有五年。基期设定为处理前一年——2019 年。用下列经典的 TWFE 事件研究声明来估计处理效应：

$$Y_{it} = \lambda_t + \alpha_i + \sum_{s \neq 2019} \mathbf{1}[s = t] \times treat_i \times \mu_s + \epsilon_{it}$$

其中， λ_t, α_i 分别表示时间和企业固定效应； $\mathbf{1}[s = t]$ 表示时间虚拟变量，即当 $s=t$ ，则为 1，其它时间为 0； $treat_i$ 为处理组虚拟变量，属于处理组为 1，否则为 0； ϵ_{it} 表示误差项； μ_s 表示每一年的处理效应，使用稳健标准误。

对上述 TWFE 事件研究模型运行 1000 次蒙特卡洛模拟，结果如图 1 所示。从结果可以看出，无论是处理前系数还是处理后动态效应，在基于固定效应的选择机制下，经典的 TWFE 事件研究均可以得到无偏的估计量。



DGPs基于固定效应的选择机制。1000次蒙特卡洛模拟。

Figure 1: 蒙特卡洛模拟：真实处理效应和 TWFE

3.2 基于未处理潜在结果的选择机制

考察一个两年 ($t=2023, 2024$), 34 个省份 ($p=1, \dots, 34$) 的面板数据, 每个省份有 100 家企业, 共 6800 个样本 ($i=1, \dots, 6800$)。2023 年企业没有进入碳交易市场, 2004 年部分企业选择进入碳交易市场, 定义 $g = 2024$ 为企业的初次处理时点。结果变量 Y_{it} 表示企业的碳排放量, 其数据产生过程 (DGPs) 为:

$$Y_{it} = (g - t) + \alpha_p + \tau_{it} + \epsilon_{it} \quad (7)$$

其中, $(g - t)$ 表示时间趋势, 即企业碳排放量随着时间变化的效应; α_p 表示省份固定效应, 抽样于最小值为 1, 最大值为 3400 的均匀分布, 即 $\alpha_i \sim U(1, 3400)$; $\epsilon_{it} \sim N(0, 10)$ 是误差项, 其服从均值为 0, 方差为 10 的正态分布。 τ_{it} 表示个体 i 在时点 t 的处理效应, 其生成过程:

$$\tau_{it} = \mu \times G_i(\omega_i) \quad (8)$$

其中, $G_i(\omega_i) = \mathbf{1}\{E[Y_{i1}(0)|\omega_i] \geq E[Y_{i1}^{p50}(0)|\omega_i]\}$ 指代选择机制, 即未进入碳交易市场的潜在碳排放量超过所有企业潜在碳排放量的 50% 分位时, 企业选择进入碳交易市场。且 μ 表示企业的瞬时处理效应, 令 $\mu = 9000$ 。这意味着企业进入碳交易市场对碳排放量的真实效应为 9000。

使用上述模拟数据可以计算出每个处理个体 i 的真实处理效应, 以及平均处理效应 ATE 和处理组的平均处理效应 ATT, 这三项处理效应均相同, 为 9000, 如图 2 所示。

下面, 用模拟数据来计算平行趋势假设 $E[Y_{i2024}(0) - Y_{i2023}(0)|G_i = 1] = E[Y_{i2024}(0) - Y_{i2023}(0)|G_i = 0]$, 以及用 DID 差分量来计算 $ATT = E[Y_{i2024} - Y_{i2023}|G_i = 1] - E[Y_{i2024} - Y_{i2023}|G_i = 0]$ 。其中, 结果变量后带 (0) 表示潜在结果, 不带则为观测结果。为了验证平行趋势假设, 分别计算潜在结果的四个均值 $E[Y_{i2024}(0)|G_i = 1]$, $E[Y_{i2023}(0)|G_i = 1]$, $E[Y_{i2024}(0)|G_i = 0]$, $E[Y_{i2023}(0)|G_i = 0]$, 如表 1 的 Panel A 所示。为了计算 DID 差分量, 分别计算观察结果的四个均值 $E[Y_{i2024}|G_i = 1]$, $E[Y_{i2023}|G_i = 1]$, $E[Y_{i2024}|G_i = 0]$, $E[Y_{i2023}|G_i = 0]$, 如表 1 的 Panel B 所示。最后, 使用双向固定效应 (TWFE) 模型 $Y_{it} = G_p + Post_t + \mu G_i \times Post_t + \epsilon_{it}$ 来估计处理效应的系数 μ , 如表 1 的 Panel C 所示。




Figure 2: 个体处理效应、ATE 和 ATT

Table 1: 处理前后结果变量均值与 DID 估计量				
Panel A: 平行趋势假设				
组群	年份	均值	一阶差分	平行趋势
处理组	2023	2554.232	-1	0
	2024	2553.232		
控制组	2023	854.7286	-1	
	2024	853.7286		
Panel B:DID 估计量				
组群	年份	均值	一阶差分	双重差分
处理组	2023	2554.232	8999	9000
	2024	11553.23		
控制组	2023	854.7286	-1	
	2024	853.7286		
Panel C:TWFE 的 DID 估计量				
$\hat{\mu}$	9000(23.46821)			
注：括号中数值为稳健标准误				

表 1 显示，当企业基于未处理潜在结果来选择进入处理时，例如，企业基于处理前的碳排放量 $Y_{i2023}(0) = Y_{i2023}$ 来决定是否进入碳交易市场。这种选择机制并不会打破平行趋势，即表 1 的 Panel A 在没有发生处理时，处理组处理前后的变化趋势等于控制组处理前后的变化趋势。此时，平行趋势假设成立，双重差分所计算的四个均值差分为 9000。且用 TWFE 模型来估计 DID 估计量得到的 $ATT=9000$ ，且在 95% 的置信水平上显著。这意味着，当处理配置机制是基于未处理潜在结果的选择时，TWFE-DID 估计量是无偏的。

3.3 基于未处理潜在结果变化的选择机制

考察一个由 6 个地区 ($p=1, \dots, 6$)，十年 ($t=2015, \dots, 2024$) 所组成的面板数据。每个地区有 1000 家企业，共 60000 个样本，企业用 i 表示。假设 2019 年建设碳排放权交易市场，有些企业决定参与其中，另一些企业则没有参与，定义初次参与时点 $g = 2019$ ，也就是说，对于参与碳交易市场的企业处理后有五期：2020、2021、2022、2023、2024；而 2015-2019 则为五个处理前时期。结果变量 Y_{it} 表示企业的碳排放量，其数据产生过程 (DGPs) 为：

$$Y_{it} = Trend + \alpha_p + \tau_{it} + \epsilon_{it} \quad (9)$$

其中， $Trend = 5$ 表示恒定的碳排放趋势，即企业每年固定的碳排放量； α_i 表示企业固定效应，抽样于最小值为 1000，最大值为 2000 的均匀分布，即 $\alpha_i \sim U(1000, 2000)$ ； $\epsilon_{it} \sim N(0, 10)$ 是误差项，其服从均值为 0，方差为 10 的正态分布。 τ_{it} 表示个体 i 在时点 t 的处理效应，其生成过程：

$$\tau_{it} = \mu \times G_i(\omega_i) \quad (10)$$

其中， $G_i(\omega_i) = \mathbf{1}\{E[\Delta Y_{i2019}(0) = Y_{i2019}(0) - Y_{i2018}(0)|\omega_i] \geq E[0|\omega_i]\}$ 指代选择机制，即 2018-2019 年的潜在碳排放量的变化大于 0，也就是企业的碳排放量在处理前增加，企业会选择进入碳交易市场。且 μ 表示企业的瞬时处理效应，令 $\mu_{2020} = 100, \mu_{2021} = 300, \mu_{2022} = 500, \mu_{2023} = 700, \mu_{2024} = 900$ 。这意味着企业进入碳交易市场对碳排放量的真实处理效应随着时间而提高，即分别为 100, 300, 500, 700 和 900。

企业选择进入处理是基于处理前潜在结果的变化，这种选择机制也是著名的“阿申菲尔特沉降 (Ashenfelter Dip)”。它是由著名劳动经济学家 Ashenfelter 在 1978 年研究就业培训项目的效应时发现的，它的本质是个体选择进入处理是基于处理前结果的变化，例如，工人发现过去两年的收入呈现下降的趋势，因此决定参加就业培训项目，提升人力资本。

上述模拟数据的潜在结果 $Y(0)$ 的演化路径如图 3 所示。处理组在 2018-2019 年经历了碳排放量上升的变化。³这就是一种“阿申菲尔特沉降”选择机制。研究者通常认为这种选择机制可能给 DID 带来严重的内生性问题，因为企业选择进入处理是基于结果变量的变化，从而使得处理后的 DID 估计系数产生偏误。实际上，在“阿申菲尔特沉降”选择机制

³更多的数据特征与性质见附录。




Figure 3: 处理组和控制组的潜在结果 $Y(0)$ 演化路径

下，研究者应该尤其关注应用研究实践中最常用的处理前趋势检验——TWFE 事件研究的处理前系数。学者们已经关注到了用 TWFE 事件研究法来进行处理前趋势检验，并指出处理前单一系数的显著性或者联合显著性检验并不能为 DID 平行趋势假设提供有效的经验证据 (Kahn-Lane and Lang, 2020; Roth, 2023)。换句话说，在“阿申菲尔特沉降”选择机制下，处理后 TWFE 事件研究系数可能是无偏的，反而是处理前系数有偏。下面，用模拟数据演示这一结果。


在“阿申菲尔特沉降”选择机制下，本文的模拟数据处理发生在 2020 年，因此，处理前有五年，处理后有五年。基期设定为处理前一年——2019 年。本文用下列经典的 TWFE 事件研究声明来估计处理效应：

$$Y_{it} = \alpha_p + \lambda_t + \alpha_i + \sum_{s \neq 2019} \mathbf{1}[s = t] \times treat_i \times \mu_s + \epsilon_{it}$$

其中， $\alpha_p, \lambda_t, \alpha_i$ 分别表示地区、时间和企业固定效应； $\mathbf{1}[s = t]$ 表示时间虚拟变量，即当 $s=t$ ，则为 1，其它时间为 0； $treat_i$ 为处理组虚拟变量，属于处理组为 1，否则为 0； ϵ_{it} 表示误差项； μ_s 表示每一年的处理效应，使用稳健标准误。

本文分别估计了带有企业固定效应和无企业固定效应的 TWFE 事件研究系数，如图 4 所示。从处理后的 ols 估计系数可以看出，经典的 TWFE 事件研究可以无偏地估计出处理效应，即 2020-2024 年的处理效应估计量分别为 100, 300, 500, 700 和 900。它们也是真实的

处理效应。因此，在“阿申菲尔特沉降”选择机制下，经典的 TWFE 事件研究可以得到无偏的处理后动态效应。



注：带有柱状的ols系数表示95%的置信区间，而包含企业固定效应的系数也包含95%置信区间，只是非常小，显示不明显。

Figure 4: TWFE 事件研究图：两种 ols 估计系数

“阿申菲尔特沉降”选择机制不会导致经典 TWFE 事件研究处理后的估计系数产生偏误是因为事件研究本身的基期是2019年，即处理前是 Y_{i2019} ，而不是处理前结果变化 $\Delta Y_{i2019} = Y_{i2019} - Y_{i2018}$ 。也就意味着，对于 TWFE 事件研究声明来说，“阿申菲尔特沉降”选择机制并没有打破基期为2019年的平行趋势假设。从模拟数据的 DGPs 来看，未处理的潜在结果 $Y_{it}(0) = Trend + \alpha_p + \epsilon_{it}$ 并不依赖于企业特征，也不依赖于未处理潜在结果的变化 $\Delta Y_{it}(0)$ 。因此，当用经典的 TWFE 事件研究来估计处理后的系数时，依赖的是处理前一期 $Y_{it}(0)$ ，如果没有发生处理，处理后的潜在结果 $Y_{it}(0)$ 仍然会回到基期的潜在结果路径上，这保证了平行趋势假设成立，所以处理后的系数是真实处理效应的无偏估计。

现在转向 TWFE 事件研究处理前系数。在经验研究中，研究者最常用的处理前趋势检验就是事件研究处理前单一系数的显著性或者联合显著性 (Roth, 2023)。图4中，虽然无企业固定效应的处理前系数均在95%的置信水平上不显著，但是当控制住企业固定效应后，处理前系数在95%置信水平上显著，且两类回归系数方向在处理前所有时期均在0以下。这意味着，“阿申菲尔特沉降”选择机制可能会导致经典的 TWFE 事件研究处理前系数产生偏误，从而导致处理前趋势检验通不过。这可能就是处理前单一系数的显著性或者联合显著性检验并不能为 DID 平行趋势假设提供有效的处理前经验证据 (Kahn-Lane and Lang, 2020; Roth, 2023) 的原因之一。

总而言之，“阿申菲尔特沉降”选择机制虽然不会导致处理后的系数有偏误，但可能导致处理前系数有偏，从而使得经验研究中常用的处理前趋势检验变得无效。之所以“阿申菲尔特沉降”选择机制不会使得处理后系数产生偏误，而使得经典的处理前趋势检验方法无效，是因为经典的 TWFE 事件研究每个时期的系数都是相对基期的相对效应 (Huntington-Klein, 2022)。在没有发生处理时，处理后的潜在结果演化路径会恢复到基期的潜在结果路径，从而保证处理后的平行趋势假设成立。但处理前，处理组经历了结果的上升 $\Delta Y_{it} > 0$ ，因此，相对于基期来说，处理前的其它时期都比基期结果要小，因此，即使没有发生处理，处理前系数也为负⁴。

既然是由于“阿申菲尔特沉降”选择机制在处理前结果变量的变化导致经典 TWFE 事件研究的处理前趋势检验无效，那么，研究者可以选择“处理前所有时期的平均”作为基期，或者控制住处理前结果变量的变化趋势。Dube et al. (2023) 将 Jorda (2005) 提出的局部投影 (Local Projection) 法应用于 DID 设计，提出一种新的局部投影法 DID 估计量 (LPDID)。LPDID 方法的一个显著特征是它允许控制处理前的时变特征，包括结果变量变化⁵不同于经典的 TWFE 事件研究声明，LPDID 声明意味着处理前任意的滞后期变量都可以包含中估计方程中。

在吸收型二值处理变量情形中，一个包含 K 阶滞后结果变量的 LPDID 声明如下：

$$Y_{it+h} - Y_{it-1} = \underbrace{\mu_h^{LPDID} \Delta D_{it}}_{\text{处理变量}} + \underbrace{\sum_{k=-1}^K \gamma_k^h \Delta Y_{it+k}}_{\text{处理前结果变量动态}} + \underbrace{\alpha_t^h}_{\text{时间效应}} + \epsilon_{it}, h = 0, \dots, H \quad (11)$$

根据“阿申菲尔特沉降”选择机制的模拟数据，处理前两期结果发生变化，因此，设定 $K=-2$ ，即式 (11) 中控制处理前两期结果的动态：一种是直接控制处理前两期结果变量，如图 5 (a) 所示，另一种是控制处理前两期结果的变化，如图 5 (b) 所示⁶。此外，设定处理前三期的平均水平为基期水平，也就是说，所有的事件研究系数都是相对于处理前三期的平均水平。

从图 5 的事件研究系数来看，在“阿申菲尔特沉降”选择机制下，LPDID 的处理前系数在 0 上下波动，且非常接近于 0，在 95% 置信水平下不显著。而处理后几乎所有系数都落在真实处理效应点上，而且在 95% 置信水平下显著。这可能意味着，估计量仍可以在“阿申菲尔特沉降”选择机制下，LPDID 估计量既可以得到有效的处理前趋势检验，又可以得到无偏的处理后系数，即 LPDID 是“阿申菲尔特沉降”选择机制的稳健估计量。

下面，使用蒙特卡洛模拟进行 1000 次经典 TWFE 事件研究和 LPDID 的模拟估计。结

⁴结果见附录图 4：“阿申菲尔特沉降”选择机制下潜在结果的 ols。

⁵局部投影法是为宏观经济时间序列数据提出的一种效应评估方法，它可以充分利用时间序列滞后变量动态特征，例如，包含之后期的结果变量或者结果变量的变化，更详细的论述参考 Jorda (2023) 和 Jorda and Taylor (2024)。

⁶需要注意的是，事件研究图中的所有系数均包含 95% 的置信区间，只是本文设定的事件研究声明可以较好的拟合模拟数据，从而使得置信区间较小，显示不明显。

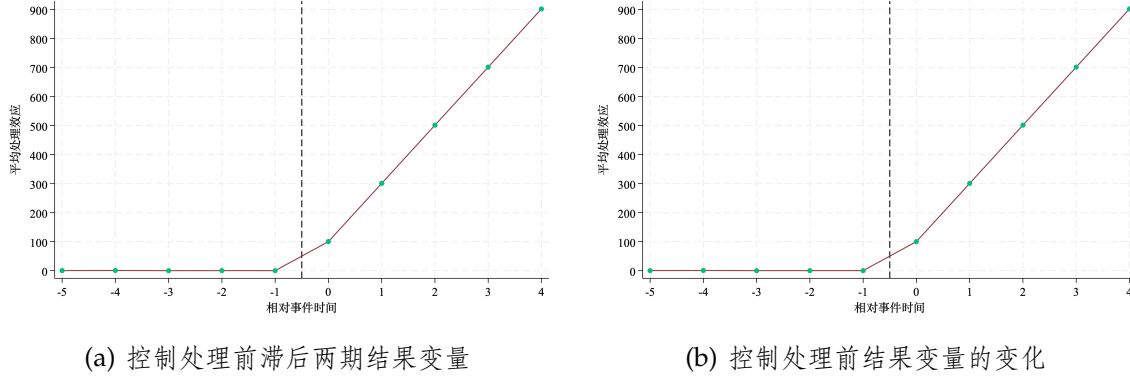


Figure 5: 事件研究图：LPDID

果如图 6 所示，1000 次蒙特卡洛模拟后的处理前后系数仍然显示，经典 TWFE 事件研究和 LPDID 的处理后估计系数是无偏的，点估计量的大小与真实处理效应相同，95% 的置信区间也非常小，而处理前时期，TWFE 事件研究点估计量均显著为负，处理前趋势检验并未通过，LPDID 的处理前系数则基本为 0，通过处理前趋势检验。


3.4 基于处理前可观测协变量的选择机制

考察一个由 34 个地区 ($p=1, \dots, 34$)，十年 ($t=2015, \dots, 2024$) 所组成的面板数据。每个地区有 50 家企业，共 17000 个样本，企业用 i 表示。假设 2019 年建设碳排放权交易市场，政府决定根据企业的经营年限 (age_i) 和规模 ($size_i$) 来选择企业参与其中。定义初次参与时点 $g = 2019$ ，也就是说，对于参与碳交易市场的企业处理后有五期：2020、2021、2022、2023、2024；而 2015-2019 则为五个处理前时期。结果变量 Y_{it} 表示企业的碳排放量，其数据产生过程 (DGPs) 为：

$$Y_{it} = Trend_t + \alpha_p + \tau_{it} + \gamma_t age_i + \lambda_t size_i + \epsilon_{it} \quad (12)$$

其中， $Trend_t = 100(year - 2015) + 1001[year \geq 2020]$ 表示时变碳排放趋势，且处理组和控制组的时变碳排放趋势存在差异； α_p 表示地区固定效应，处理组固定效应为 4000，控制组固定效应为 5000； $age_i \sim N(35, 10)$ 表示企业处理前的经营年限，抽样于均值为 35，方差为 10 的正态分布； $size_i \sim N(2, 0.5)$ 表示企业处理前的规模，抽样于均值为 2，方差为 0.5 的正态分布；而且企业经营年限与规模对碳排放量的影响是时变的，即 $\gamma_t = 10 + 5(year - 2015) + 251[year \geq 2020]$ 和 $\lambda_t = 100 + 50(year - 2015) + 1001[year \geq 2020]$ ； $\epsilon_{it} \sim N(0, 150)$ 是误差项，其服从均值为 0，方差为 150 的正态分布。 τ_{it} 表示个体 i 在时点 t 的处理效应，其生成过程：

$$\tau_{it} = \mu \times G_i(\omega_i) \quad (13)$$



注：DGPs使用基于处理前潜在结果变化的平行趋势假设；所有回归均包含企业固定效应；LPDID使用处理前三期作为基期，且控制处理前结果变化；1000次蒙特卡洛模拟。

Figure 6: 蒙特卡洛模拟：真实处理效应、TWFE 和 LPDID

其中， $G_i(\omega_i) = \mathbf{1}\{E[U(0,1)|\omega_i] \leq E[\text{propensity}|\omega_i]\}$ 指代选择机制，且处理的倾向得分 $\text{propensity} = 0.3 + 0.31[\text{age}_i > 0] + 0.21[\text{size}_i > 0]$ 与企业运营年限和规模有关，而选择机制为企业接受处理的倾向得分大于其平均值时，则选择进入处理。且 μ 表示企业的瞬时处理效应。

根据上述 DGPs，需要说明的是，处理前协变量（例如，企业运营年限和规模）对处理组和控制组的碳排放量有异质性效应。这是经验研究中经常遇到的情形。当选择机制基于可观测的协变量时，经验研究者通常会在 TWFE 中直接控制协变量，本文将企业运营年限和规模，其各自的平方项，以及它们的交互项均作为控制变量引入 TWFE 中，以尽可能控制协变量对结果变量的影响，方程声明如下：

$$\begin{aligned}
 Y_{it} = & \alpha_p + \lambda_t + \alpha_i + \sum_{s \neq 2019} \mathbf{1}[s = t] \times \text{treat}_i \times \mu_s \\
 & + \gamma_1 \text{age}_i \times t + \lambda_1 \text{size}_i \times t \\
 & + \gamma_2 \text{age}_i^2 \times t + \lambda_2 \text{size}_i^2 \times t + \eta \text{age}_i \times \text{size}_i \times t \\
 & + \epsilon_{it}
 \end{aligned} \tag{14}$$

使用 1000 次蒙特卡洛模拟运行上述 TWFE，结果如图 7 所示。从图 7 的蒙特卡洛模拟结果可以看出，即使在 TWFE 中控制了所有可能的协变量，TWFE 的估计量仍然有偏，无

论是处理前系数的向下偏误，还是处理后系数向上偏误，TWFE 中每一期的系数都是有偏的。这是因为在 TWFE 回归中控制协变量主要考虑的是“遗漏变量偏误”——基于可观测协变量选择机制可能带来的遗漏变量偏误，但是却忽略了“条件平行趋势”问题。

“条件平行趋势”是由 Heckman et al. (1997) 提出，Abadie (2005) 和 Sant’ Anna and Zhao (2020) 均使用这个假设。“条件平行趋势”指的是，处理组和控制组的个体构成不同，例如，两个组群个体的协变量分布具有较大差异。由于处理组和控制组在协变量方面具有明显的差异，因此，研究者通常怀疑“平行趋势假设”是否成立。实际上，一旦研究者相信基于某些协变量（例如，企业规模），平行趋势假设在处理组和控制组之间就是成立的，只不过企业规模为 500 万水平的平行趋势与规模为 1000 万水平的平行趋势是不同的，这就是“条件平行趋势假设”。

“条件平行趋势”主要是指不同的企业在协变量方面具有不同的特征，而具有相似（相同）协变量的企业在没有发生处理时的潜在结果具有相似（相同）的变化趋势。在基于可观测协变量的选择机制 DGPs 中，随着其运营年限和规模的增长，企业选择进入处理的概率就越大，即 $propensity = 0.3 + 0.31[age_i > 0] + 0.21[size_i > 0]$ ，且倾向得分大于平均水平时，企业就选择进入处理。也就是说，最终进入碳交易市场的企业在运营年限和规模方面应该都超过了控制组企业的运营年限和规模。而“条件平行趋势”试图通过协变量来使得两个具有明显差异的组群的“平行趋势假设”成立。


总之，在 TWFE 事件研究声明 (14) 中，控制协变量——企业年限和企业规模——并不能解决“条件平行趋势”的问题。

“条件平行趋势假设”的本质是处理组和控制组的构成在协变量方面存在差异。因此，在基于可观测协变量的选择机制下，可以在 DID 中引入匹配策略。Sant’ Anna and Zhao (2020) 提出了一种双重稳健 (double-robust) 估计量，Callaway and Sant’ Anna (2021) 将其引入 DID 研究设计中（后简称 CSDID）。CSDID 假设条件于可观测变量的平行趋势。

CSDID 定义初次处理类别 (cohorts) g (例如， $g=2019$)，并将 DID 的因果参数定义为时期 t 组群类别 g 的平均处理效应 ATE 的函数。假设有 T 期， D_t 表示处理变量，如果个体接受处理为 1，否则为 0。定义 G_g 为处理类别虚拟变量，即处理个体属于处理类别 g 为 1，否则为 0， C 为二值型变量，对于从未处理个体为 1，否则为 0。对于每个个体， G_g 和 C 至少有一个为 1。定义广义倾向得分 $p_g(X) = P(G_g = 1|X, G_g + C = 1)$ ，它是条件于协变量 X 和处理类别 g 或者控制组类别 C ，个体接受处理的概率。

让 $Y_t(1)$ 和 $Y_t(0)$ 分别表示时期 t 的处理潜在结果和未处理潜在结果。那么，每个时期的观测结果为： $Y_t = D_t Y_t(1) + (1 - D_t) Y_t(0)$ 。CSDID 发展了一种非参数识别策略来识别感兴趣的处理效应参数 $ATT(g, t)$ 。在条件平行趋势假设下，

$$ATT(g, t) = \mathbb{E} \left[\left(\frac{G_g}{\mathbb{E}[G_g]} - \frac{\frac{p_g(X)C}{1-p_g(X)}}{\mathbb{E} \left[\frac{p_g(X)C}{1-p_g(X)} \right]} \right) (Y_t - T_{g-1}) \right] \quad (15)$$



DGPs使用条件于协变量的平行趋势假设，且TWFE包含所有的协变量。1000蒙特卡洛模拟。


Figure 7: 蒙特卡洛模拟：真实处理效应、带协变量的 TWFE

CSDID 的双重稳健策略将 Abadie (2005) 的倾向得分加权 (propensity score weighting) 法与 Heckman et al. (1997) 的回归调整 (regression adjustment) 法结合在一起。研究者的数据只需要满足其中一个方法就可以得到无偏估计量。用模拟数据运行 1000 次 CSDID 的蒙特卡洛模拟，结果如图 8 所示。CSDID 的处理前和处理后估计系数均是无偏的。

3.5 基于处理效应的选择机制

当企业基于处理效应来选择进入处理时，因果推断会遇到极大的挑战。因为企业会基于收益最大化来做出处理决策，例如，企业预期到进入碳交易市场的收益为正，它就会选择进入处理，此时，处理组的企业都会有正的收益，控制组个体都会有负的收益。这就是著名的罗伊 (Roy) 自选择机制 (Roy, 1951)。罗伊研究了人们根据未来的工资来最优地选择职业。Borjas (1987) 通过研究移民对工资收入的影响正式理论化了罗伊自选择机制。在移民自选择机制中，移民可以预期到移入国家的工资收入，进而做出移民决策。从这个意义上来看，个体根据其处理效应，选择最有利于自身的处理状态。在现实中，个体无法同时观测到两种处理状态，这导致了因果效应识别具有较大挑战。

考察一个由 34 个地区 ($p=1, \dots, 34$)，十年 ($t=2015, \dots, 2024$) 所组成的面板数据。每个地区有 50 家企业，共 17000 个样本，企业用 i 表示。假设 2019 年建设碳排放权交易市场，定义初次参与时点 $g = 2019$ ，也就是说，对于参与碳交易市场的企业处理后有五期：2020、



DGPs使用条件于协变量的平行趋势假设，且TWFE包含所有的协变量，CSDID使用双重稳健估计量。
1000蒙特卡洛模拟。

Figure 8: 蒙特卡洛模拟：真实处理效应、带协变量的 TWFE 和 CSDID

2021、2022、2023、2024；而 2015-2019 则为五个处理前时期。结果变量 Y_{it} 表示企业的碳排放量，其数据产生过程 (DGPs) 为：

$$Y_{it} = Trend_t + \alpha_p + \tau_{it} + \gamma_t age_i + \lambda_t size_i + \epsilon_{it} \quad (16)$$

其中， $Trend_t = 100(year - 2015) + 1001[year \geq 2020]$ 表示时变碳排放趋势，且处理组和控制组的时变碳排放趋势存在差异； α_p 表示地区固定效应，处理组固定效应为 4000，控制组固定效应为 5000； $age_i \sim N(35, 10)$ 表示企业处理前的经营年限，抽样于均值为 35，方差为 10 的正态分布； $size_i \sim N(2, 0.5)$ 表示企业处理前的规模，抽样于均值为 2，方差为 0.5 的正态分布；而且企业经营年限与规模对碳排放量的影响是时变的，即 $\gamma_t = 10 + 5(year - 2015) + 251[year \geq 2020]$ 和 $\lambda_t = 100 + 50(year - 2015) + 1001[year \geq 2020]$ ； $\epsilon_{it} \sim N(0, 150)$ 是误差项，其服从均值为 0，方差为 150 的正态分布。 τ_{it} 表示个体 i 在时点 t 的处理效应，其生成过程：

$$\tau_{it} = \mu \times G_i(\omega_i) \quad (17)$$


其中， $G_i(\omega_i) = \mathbf{1}\{E[\mu_i|\omega_i] \leq E[0|\omega_i]\}$ 指代选择机制。基于这种处理效应的选择机制意味着，根据企业的平均处理效应 $E[\mu_i|\omega_i]$ 来选择其大于 0 的企业进入处理。⁷

⁷需要强调的是，在现实世界中，研究者不可能在处理前观测到处理效应。

下面，用上述 DGPs 对经典 TWFE 事件研究设计和 CSDID 进行 1000 次蒙特卡洛模拟。经典 TWFE 事件研究设计声明如下：

$$Y_{it} = \alpha_p + \lambda_t + \alpha_i + \sum_{s \neq 2019} \mathbf{1}[s = t] \times treat_i \times \mu_s + \gamma_1 age_i \times t + \lambda_1 size_i \times t + \epsilon_{it} \quad (18)$$

真实处理效应、TWFE 估计量和 CSDID 估计量的蒙特卡洛模拟结果如图 9 所示。从结果可以看出，无论是经典的 TWFE 事件研究设计，还是双重稳健估计量 (CSDID)，在基于处理效应的选择机制下均无法得到无偏的估计量。这主要是因为在这种 DGPs 中，处理组和控制组之间的平行趋势假设并不成立。因此，要求平行趋势假设的估计量可能均不适用于“基于处理效应的选择机制”下因果效应的估计。⁸



DGPs使用条件于协变量的平行趋势假设，且TWFE包含所有的协变量，CSDID使用双重稳健估计量。1000蒙特卡洛模拟。

Figure 9: 蒙特卡洛模拟：真实处理效应、TWFE 和 CSDID

⁸为此，Heckman and Vytalil (2005) 发展了边际处理效应 (The Marginal Treatment Effect, MTE) 框架，可以更加灵活地应对罗伊选择机制，但这超出了本文的讨论范围。故留作未来的研究方向。

4 结论与实践建议

本文通过蒙特卡洛模拟方法研究了选择进入处理的不同机制对 DID 研究设计因果效应估计的影响，研究结论如下：在五种常见的选择机制下，

第一，基于固定效应、未处理潜在结果的选择机制并不会导致经典的 TWFE 估计量产生偏误；

第二，基于可观测协变量和未处理潜在结果变化的选择机制则会导致经典 TWFE 事件研究处理前估计系数产生偏误，从而使得常用的处理前趋势检验方法无效，但基于未处理潜在结果变化的选择并不会导致经典 TWFE 处理后估计系数产生偏误，而基于可观测协变量的选择机制则会导致经典 TWFE 处理后估计系数产生偏误。为了纠正基于未处理潜在结果变化的选择机制可能引起的偏误，研究者可以使用控制处理前结果变量或者处理前结果变化的方法，例如 LPDID 估计量。而纠正基于可观测协变量的选择机制可能引起的偏误，研究者可以使用双重稳健估计量，例如 CSDID。

第三，基于处理效应的选择机制会打破平行趋势假设，从而使得现有的 DID 估计量产生较大的偏误。这种选择机制对因果效应识别带来了许多障碍，需要更合适的研究设计。

在观测研究中，研究者无法观测到两种处理状态的反事实结果，因此，很难定量发现选择机制是哪种类型。基于此，正如 Rubin (2007) 和 Imbens and Xu (2024) 所指出的，“因果效应分析应该从理解处理配置机制开始”。因此，在研究设计阶段，研究者应该仔细地收集、整理关于选择进入处理的经济社会制度等背景信息，或者根据理论知识来充分理解个体选择进入处理的动机与过程。经济学家 Pedro Sant’ Anna 建议研究者要尽可能弄清楚“谁决定处理”“决策者知道关于处理的什么信息”“处理类型是什么”。

参考文献

Roy AD. Some thoughts on the distribution of earnings. *Oxford Economic Papers*, 1951, 3:135–146.

Borjas, G. J. (1987). "Self-Selection and the Earnings of Immigrants". *American Economic Review*. 77 (4): 531–553.

Heckman, J. J.; Honoré, B. E. (1990). "The Empirical Content of the Roy Model". *Econometrica*. 58 (5): 1121–1149.

Heckman, J. J.; Vytlačil, E. (2007). "Econometric evaluation of social programs, part I: Causal models, structural models and econometric policy evaluation". In Heckman, J. J.; Leamer, E. E. (eds.). *Handbook of Econometrics*. Vol. 6. North Holland.

Haavelmo T. The probability approach in econometrics. *Econometrica*, 1944, 15:413–419.

Rubin DB. Bayesian inference for causality: the importance of randomization. *The Proceedings of the Social Statistics Section of the American Statistical Association*. American Statistical Association: Alexandria, VA, 1975, 233–239.

Rubin D B. The design versus the analysis of observational studies for causal effects: parallels with the design of randomized trials[J]. *Statistics in medicine*, 2007, 26(1): 20-36.

Neyman J. On the application of probability theory to agricultural experiments: essay on principles, Section 9. *Annals of Agricultural Science* 1923; Translated in *Statistical Science* 1990; 5(4):465–472.

Fisher RA. *Statistical Methods for Research Workers*. Oliver and Boyd: Edinburgh, 1925.

Miller, Douglas L., Na'ama Shenhav, and Michel Grosz. "Selection into identification in fixed effects models, with application to Head Start." *Journal of Human Resources* 58.5 (2023): 1523-1566.

Imai, Kosuke, and In Song Kim. "When should we use unit fixed effects regression models for causal inference with longitudinal data?." *American Journal of Political Science* 63.2 (2019): 467-490.

Heckman, James J., and Christopher Taber. "Roy model." *Microeconometrics*. London: Palgrave Macmillan UK, 2010. 221-228.

附录

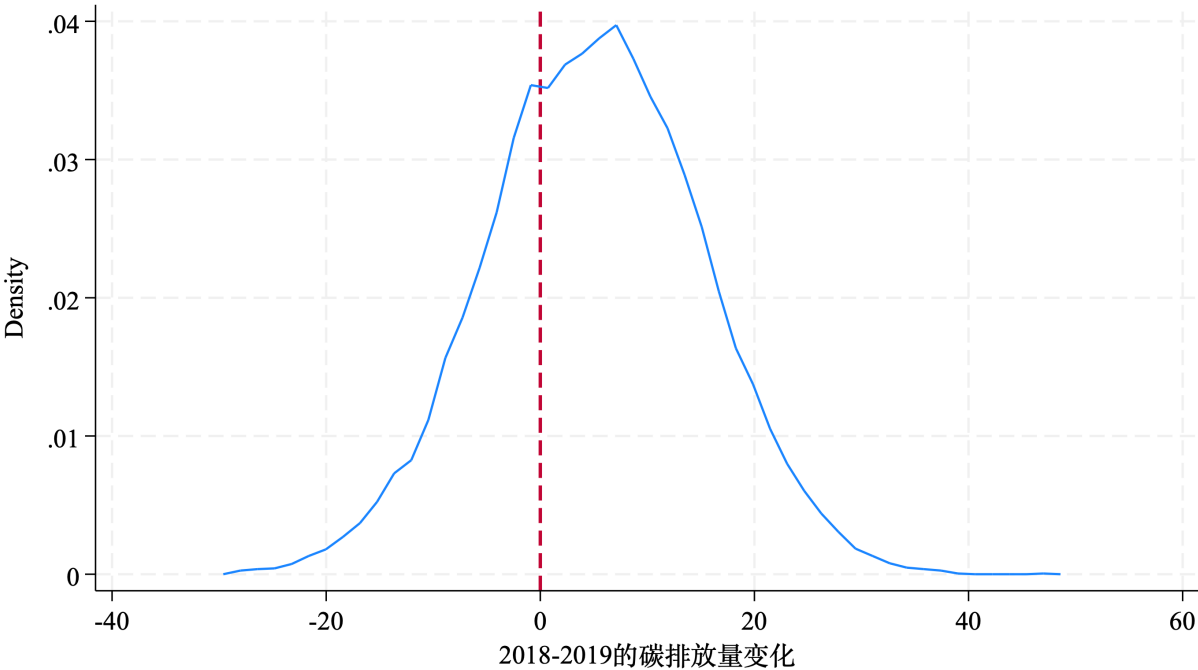


Figure 10: 附图 1. 处理组和控制组的核密度分布




Figure 11: 附图 2. 2019 年处理组和控制组的 Y(0) 均值




Figure 12: 附图 3. 事件研究图：“阿申菲尔特沉降”选择机制下 ols 估计系数




Figure 13: 附图 4. 事件研究图：“阿申菲尔特沉降”选择机制下潜在结果的 ols